

Proposal Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Hidayah Atma Negara (24031554169)
Anggota 1	Najwa Ayu Ramdhani (24031554168)
Anggota 2	Alvida Lewiana (24031554198)
URL Github	https://github.com/atmamta/PROJECT-PEMBELAJARAN-MESIN

Informasi Umum Proyek

Judul	Analisis Perbandingan Model Ensemble dan Non-Ensemble dengan Teknik Oversampling SMOTE untuk Prediksi Keparahan Efek Samping Obat pada Sistem Pelaporan Kejadian Buruk FDA 2015 - 2025 (FAERS)
Topik	Kesehatan
Pilihan Rumusan Masalah	Pemanfaatan AI dan Big Data Kesehatan
Revisi?	<i>Ya / Tidak</i>

Deskripsi Rumusan masalah	Setiap tahun, jutaan pasien di seluruh dunia mengonsumsi obat-obatan untuk berbagai kondisi kesehatan. Meskipun obat-obatan ini dirancang untuk menyembuhkan, tidak jarang timbul efek samping yang tidak diinginkan, bahkan dapat berakibat fatal. Keterlambatan dalam mendeteksi efek samping obat yang fatal dapat berakibat pada kerugian nyawa dan beban biaya kesehatan yang masif. Di tengah pesatnya peluncuran obat-obat baru, kebutuhan akan sistem deteksi dini berbasis kecerdasan buatan menjadi sangat mendesak untuk menjamin keselamatan pasien dengan mengidentifikasi laporan secara efisien. Kemampuan untuk memprediksi status keseriusan efek samping obat akan sangat membantu otoritas kesehatan dan produsen farmasi dalam memprioritaskan investigasi keamanan obat dan risiko. Permasalahan ini, khususnya dalam mengidentifikasi efek samping obat yang serius secara otomatis, masih menjadi tantangan besar dan belum terselesaikan sepenuhnya karena beberapa alasan utama: 1. Data pelaporan efek samping obat sangat besar dan heterogen, mencakup informasi klinis, demografis, dan naratif yang kompleks. Mengurai pola dari data semacam ini membutuhkan pendekatan yang canggih. 2. Kasus efek samping obat yang benar-benar serius atau fatal jumlahnya jauh lebih banyak dibandingkan dengan kasus ringan atau non-serius. Hal ini menunjukkan bahwa permasalahan keamanan obat merupakan isu penting yang membutuhkan penanganan. 3. Dengan banyaknya informasi yang masuk, petugas sering kali kesulitan untuk menemukan pola-pola kecil atau hubungan antar data yang sebenarnya sangat penting untuk menentukan apakah suatu efek samping itu serius atau tidak.
Tujuan penelitian (Objectives)	Penelitian ini bertujuan untuk mengembangkan sistem prediksi status keseriusan dari efek samping obat dengan tahapan dan target penyelesaian sebagai berikut: 1. Mengumpulkan dan membersihkan data laporan efek samping obat dari FAERS (tahun 2015–2025). Ini termasuk mengisi data yang kosong.

	- Menggunakan SMOTE untuk menyeimbangkan data dan membandingkan data tanpa menggunakan SMOTE. - Membuat dan melatih beberapa jenis sistem prediksi dengan membandingkan Ensemble dan Non-Ensemble. - Menyajikan temuan penting dari penelitian ini, termasuk faktor-faktor apa saja yang paling berpengaruh terhadap terjadinya efek samping obat yang serius.
Referensi penelitian	Berikut jurnal dan referensi yang kami gunakan: https://doi.org/10.1097/MD.00000000000029387 https://doi.org/10.1145/3472813.3472817 https://doi.org/10.3389/fphar.2024.1497397

Informasi Detil Dataset

Sumber dataset	Dataset yang digunakan dalam penelitian ini diperoleh dari platform Kaggle, yang dapat diakses melalui tautan berikut: <u>FDA Drug Adverse Event Reports 2015 to 2025 FAERS</u>. Dataset ini bersumber dari <i>FDA Adverse Event Reporting System (FAERS)</i>, yaitu basis data utama milik Amerika Serikat yang memuat informasi laporan keamanan obat, seperti efek samping dan kejadian yang tidak diinginkan yang dikirimkan oleh para profesional kesehatan, produsen, dan pasien dari 162 negara. FAERS dikelola oleh FDA (<i>Food and Drug Administration</i>), yaitu lembaga pemerintahan Amerika Serikat yang bertanggung jawab atas pengawasan keamanan makanan, obat-obatan, produk biologis, alat kesehatan, kosmetik, dan produk kesehatan lainnya. Basis data ini dirancang untuk mendukung pengawasan keamanan dan evaluasi manfaat obat setelah dipasarkan sepanjang siklus hidup produk obat. Proses akuisisi data dilakukan dengan mengunduh dataset yang telah dikompilasi oleh pengguna Kaggle dengan nama akun kanchana1990, yang mencakup 11 tahun data dari periode tahun 2015 hingga 2025. Dataset tersedia dalam format CSV dan dapat langsung digunakan untuk analisis tanpa akuisisi tambahan.																														
Deskripsi awal fitur dataset	Dataset ini memiliki 30 atribut dan 528.000 laporan yang digunakan untuk analisis farmakovigilans , klasifikasi efek samping, dan analisis keselamatan obat. Tabel 1. Atribut Dataset <table><tr><th>Atribut</th><th>Tipe</th><th>Keterangan</th></tr><tr><td>report_id</td><td>string</td><td>Pengidentifikasi unik laporan keamanan FDA</td></tr><tr><td>receive_date</td><td>date</td><td>Tanggal menerima laporan</td></tr><tr><td>year</td><td>int</td><td>Tahun pelaporan (2015/2025)</td></tr><tr><td>month</td><td>int</td><td>Bulan pelaporan (1-12)</td></tr><tr><td>quarter</td><td>string</td><td>Laporan triwulan, misalnya 2021Q3</td></tr><tr><td>serious</td><td>string</td><td>Apakah kejadian tersebut serius (Ya/ Tidak)</td></tr><tr><td>serious_flags</td><td>string</td><td>Kategori tingkat keparahan spesifik (Kematian; Rawat inap, dll.)</td></tr><tr><td>is_fatal</td><td>bool</td><td>Benar jika kejadian tersebut mengakibatkan kematian</td></tr><tr><td>is_hospitalized</td><td>bool</td><td>Benar jika pasien dirawat di rumah sakit</td></tr></table>	Atribut	Tipe	Keterangan	report_id	string	Pengidentifikasi unik laporan keamanan FDA	receive_date	date	Tanggal menerima laporan	year	int	Tahun pelaporan (2015/2025)	month	int	Bulan pelaporan (1-12)	quarter	string	Laporan triwulan, misalnya 2021Q3	serious	string	Apakah kejadian tersebut serius (Ya/ Tidak)	serious_flags	string	Kategori tingkat keparahan spesifik (Kematian; Rawat inap, dll.)	is_fatal	bool	Benar jika kejadian tersebut mengakibatkan kematian	is_hospitalized	bool	Benar jika pasien dirawat di rumah sakit
Atribut	Tipe	Keterangan																													
report_id	string	Pengidentifikasi unik laporan keamanan FDA																													
receive_date	date	Tanggal menerima laporan																													
year	int	Tahun pelaporan (2015/2025)																													
month	int	Bulan pelaporan (1-12)																													
quarter	string	Laporan triwulan, misalnya 2021Q3																													
serious	string	Apakah kejadian tersebut serius (Ya/ Tidak)																													
serious_flags	string	Kategori tingkat keparahan spesifik (Kematian; Rawat inap, dll.)																													
is_fatal	bool	Benar jika kejadian tersebut mengakibatkan kematian																													
is_hospitalized	bool	Benar jika pasien dirawat di rumah sakit																													


	is_life_threat	bool	Benar jika peristiwa tersebut mengancam jiwa
	is_disabling	bool	Benar jika kejadian tersebut menyebabkan kecacatan
	reactions	string	Semua reaksi MedDRA yang dilaporkan (dipisahkan oleh titik koma, hingga 5)
	primary_reaction	string	Reaksi pertama/primer yang dilaporkan
	reaction_outcomes	string	Hasil pasien per reaksi
	patient_recovered	bool	Benar jika pasien sembuh atau sedang dalam masa pemulihan
	num_reaction	int	Jumlah total reaksi yang dilaporkan
	suspect_drug	string	Nama generik obat yang dicurigai
	brand_name	string	Nama merek/dagang obat yang dicurigai
	drug_route	string	Rute pemberian (Oral, Intravena, dll.)
	drug_indication	string	Kondisi medis yang menjadi alasan obat tersebut diresepkan
	manufacturer	string	Nama produsen obat
	pharm_class	string	Kelas obat farmakologis
	num_drugs	int	Jumlah obat yang dikonsumsi pasien
	drug_count_category	string	Kategori Polifarmasi (Sata obat/ 2-3 obat/ 4-5 obat/ 6 obat atau lebih)
	patient_age_years	float	Usia pasien standarisasi menjadi tahun
	age_group	string	Kelompok usia (Bayi/ Anak/ Remaja/ Dewasa/ Paruh baya/ Lansia/ Orang tua)
	patient_sex	string	Jenis kelamin pasien (Laki-laki/ Perempuan/ Tidak diketahui)
	patient_weight_kg	float	Berat pasien dalam kategorikal
	country	string	Negara tempat kejadian berlangsung (kode ISO)
	report_age_days	int	Jumlah hari sejak laporan diterima (per 28 maret 2026)
Aspek khusus dari dataset	Terdapat beberapa aspek khusus yang perlu diperhatikan dalam dataset ini, meliputi kelengkapan data, ketidakseimbangan kelas, sebaran outlier serta karakteristik umum dataset. 1. Kelengkapan Data (<i>Sparsity</i>) Dataset ini memiliki beberapa kolom yang tidak terisi secara signifikan. Berdasarkan hasil pemeriksaan missing value pada dataset dengan total		

	528.000 baris dan 30 kolom, kolom <i>patient_weight_kg</i> menjadi kolom dengan kehilangan data terbanyak, yaitu sebesar 379.923 nilai kosong atau sekitar 71,9% dari total baris. Kolom <i>serious_flags</i> memiliki 301.106 nilai kosong (57,0%), namun kondisi ini bersifat struktural karena kolom tersebut memang hanya terisi untuk laporan yang dikategorikan serius sehingga nilai kosong pada kolom ini bukan merupakan missing value yang bersifat acak. Kolom <i>patient_age_years</i> juga memiliki 151.509 nilai kosong (28,7%), sedangkan kolom lainnya tidak memiliki nilai kosong sama sekali. Penanganan missing value dilakukan dengan mengisi kolom bertipe numerik menggunakan nilai median dan kolom bertipe kategorikal menggunakan nilai modus. Setelah penanganan. 2. Ketidakseimbangan Data (<i>Class Imbalance</i>) Distribusi kolom target <i>serious</i> menunjukkan adanya ketidakseimbangan kelas yang perlu ditangani sebelum proses pemodelan. Dari total 528.000 data, sebanyak 395.000 laporan (74,8%) termasuk ke dalam kelas serius (1) dan 133.000 laporan (25,2%) termasuk ke dalam kelas non-serius (0), sehingga diperoleh imbalance ratio sebesar 2,97 : 1. Meskipun rasio ini tidak tergolong ekstrem, ketidakseimbangan tersebut tetap berpotensi menyebabkan model cenderung bias dalam memprediksi kelas mayoritas dan menurunkan kemampuan model dalam mengenali kelas minoritas. Oleh karena itu, penelitian ini menerapkan teknik SMOTE untuk membangkitkan sampel sintetis pada kelas minoritas, serta membandingkan performa model sebelum dan sesudah penerapan SMOTE. 3. Sebaran Outlier Berdasarkan visualisasi boxplot pada seluruh kolom numerik setelah proses <i>preprocessing</i>, ditemukan adanya nilai ekstrem pada beberapa kolom. Kolom <i>num_reactions</i> secara umum terpusat pada rentang rendah namun terdapat outlier hingga sekitar 250 reaksi per laporan. Kolom <i>num_drugs</i> menunjukkan pola serupa di mana mayoritas pasien mengonsumsi obat dalam jumlah kecil, namun outlier mencapai sekitar 2.000 obat yang kemungkinan merupakan kasus polifarmasi ekstrem atau kesalahan entri data. Pada kolom <i>patient_age_years</i>, distribusi terpusat pada rentang dewasa hingga lansia dengan nilai median sekitar 59 tahun, namun terdapat outlier berupa usia sangat muda (kurang dari 1 tahun) dan sangat tua (lebih dari 100 tahun). Kolom <i>patient_weight_kg</i> memiliki distribusi terpusat dengan median sekitar 72,56 kg, namun ditemukan outlier ekstrem di atas 300 kg. Keberadaan outlier pada kolom-kolom tersebut perlu diperhatikan secara khusus mengingat algoritma SVM bersifat sensitif terhadap perbedaan skala fitur, sehingga normalisasi menggunakan StandardScaler diterapkan sebagai langkah mitigasi.
--	---

Rencana Metode

Teknik yang digunakan	Berikut rencana awal teknik yang kami gunakan: 1. Untuk mengatasi masalah <i>imbalance</i> data kami menggunakan SMOTE, dimana SMOTE ini akan menghasilkan <i>sample</i> sintetis dari kelas minoritas, sehingga model dapat belajar dari data yang lebih seimbang dan tidak bias terhadap kelas mayoritas. 2. Model Non-Ensemble yang kami gunakan sebagai <i>baseline</i> perbandingan adalah <i>Support Vector Machine</i> (SVM). <i>Support Vector Machine</i> adalah algoritma yg kuat untuk klasifikasi terutama efektif pada data dengan dimensi tinggi.
-----------------------	---

	3. Model ensemble yang kami gunakan untuk peningkatan performa adalah Random Forest berbasis <i>bagging</i>. Random Forest dipilih karena mampu menghasilkan prediksi yang lebih stabil dan akurat, yang akan digunakan sebagai representasi model ensemble untuk memprediksi status "<i>serious</i>". 4. Model ensemble boosting yang kami gunakan adalah XGBoost. XGBoost mampu mengelola data yang besar dengan efisien. Dalam penelitian ini, XGBoost akan dilatih pada data FEARS.
Alasan pemilihan teknik/algoritma	Pemilihan teknik dan algoritma dalam penelitian ini didasarkan pada karakteristik dataset FEARS serta relevansinya terhadap permasalahan prediksi keparahan efek samping obat yang bersifat kompleks dan tidak seimbang. 1. SMOTE (<i>Synthetic Minority Oversampling Technique</i>) SMOTE (<i>Synthetic Minority Oversampling Technique</i>) dipilih karena penanganan ketidakseimbangan kelas karena dataset FEARS memiliki imbalance ratio sebesar 3,06 : 1 antara kelas serius dan non-serius yang berpotensi membuat model bias terhadap kelas minoritas. SMOTE bekerja dengan membangkitkan sample sintetis pada kelas minoritas melalui interpolasi antar titik data yang berdekatan sehingga distribusi kelas menjadi lebih seimbang tanpa menghilangkan informasi dari data asli. Pendekatan ini didukung oleh Hu et al (2024) yang melaporkan bahwa penggunaan SMOTE terbukti meningkatkan nilai AUC dari rentang 0,601-0,936 menjadi 0,786-0,939, serta Zhou et al (2021) yang menunjukkan peningkatan F-Measure substansial pada seluruh model setelah penanganan imbalance diterapkan. 2. SVM (<i>Support Vector Machine</i>) <i>Support Vector Machine</i> (SVM) dipilih sebagai model baseline non-ensemble karena kemampuannya menangani data berdimensi tinggi melalui pencarian <i>hyperplane</i> optimal dengan margin terbesar, serta penggunaan fungsi karek untuk menangani data yang tidak dapat dipisahkan secara linier. Kim et al (2022) dan Hu et al (2024) menempatkan SVM sebagai salah satu metode <i>supervised</i> yang paling sering digunakan dalam studi deteksi reaksi obat merugikan. Mengingat SVM sensitif terhadap perbedaan skala fitur, normalisasi menggunakan StandardScaler telah diterapkan sebagai langkah mitigasi dalam tahap <i>preprocessing</i> penelitian ini. 3. Random Forest Random Forest dipilih sebagai representasi model ensemble berbasis <i>bagging</i> karena kemampuannya menggabungkan prediksi dari banyak pohon keputusan yang dibangun secara independen, sehingga secara inheren mengurangi varians dan resiko <i>overfitting</i>. Kemampuan ini relevan mengingat dataset FEARS mengandung fitur heterogen yang mencakup data numerik, kategorikal dan boolean secara bersamaan. Hu et al (2024) menegaskan bahwa Random Forest merupakan algoritma yang paling sering digunakan dalam studi prediksi efek samping obat dengan rata-rata AUC $0,770 \pm 0,104$ sementara Irmawati Aziz (2025) melaporkan Random Forest mencapai AUC 0,891 dengan keunggulan dalam menangani data tidak seimbang pada konteks farmakovigilans. 4. XGBoost XGBoost (<i>Extreme Gradient Boosting</i>) dipilih sebagai representasi model ensemble berbasis boosting karena membangun pohon keputusan secara sekuensial, dimana setiap pohon baru difokuskan memperbaiki kesalahan prediksi sebelumnya melalui optimasi loss function dan

	regularisasi. Hu et al (2024) melaporkan XGBoost sebagai algoritma boosting paling sering diidentifikasi sebagai model optimal dengan rata-rata AUC $0,810 \pm 0,109$, melalui performa Random Forest. Zhao et al (2021) juga menunjukkan peningkatan F-Measure sebesar 24,28% pada XGBoost setelah penerapan teknik penanganan imbalance, sekaligus kemampuannya menangani sparsity data secara alami yang relevan dengan kondisi missing value pada dataset FAERS.
Langkah-langkah umum pengerjaan	Dalam penelitian ini, proses pelatihan model dilakukan melalui beberapa tahapan yang dirancang secara sistematis agar model yang dihasilkan mampu memprediksi tingkat keseriusan efek samping obat dengan lebih akurat. Berikut disajikan langkah-langkah penelitian pada Gambar 1.  <pre> graph TD Start([Start]) --> Input[/Input/] Input --> EDA[EDA] EDA --> Preprocessing[Preprocessing] Preprocessing --> SplitData[Split Data] SplitData --> FeatureSelection{Feature Selection?} FeatureSelection -- Yes --> ApplyFeatureSelection[Apply Feature Selection] ApplyFeatureSelection --> SMOTE{SMOTE?} FeatureSelection -- No --> SMOTE SMOTE -- Yes --> ApplySMOTE[Apply SMOTE] SMOTE -- No --> Model[Model] ApplySMOTE --> Model Model --> Output[/Output/] Output --> End([End]) </pre> Gambar 1. Langkah-langkah Penelitian Berdasarkan Gambar 1, tahap proses pelatihan model dimulai dengan proses input dataset FAERS 2015-2025. Setelah data dimuat, dilakukan <i>Exploratory Data Analysis</i> (EDA) untuk memahami karakteristik data seperti, distribusi kelas, statistika deskriptif, outlier, serta hubungan antar fitur. Tahap selanjutnya adalah <i>preprocessing</i>, yang meliputi penanganan missing value, encoding variabel kategorikal, normalisasi data numerik, serta penghapusan atribut yang tidak relevan. Setelah preprocessing selesai, dataset dibagi menjadi data <i>training</i>, <i>testing</i>, dan <i>validation</i> dengan rasio 70:15:15. Selanjutnya dilakukan eksperimen <i>feature selection</i> untuk memilih fitur-fitur yang paling berpengaruh terhadap tingkat keparahan efek samping obat. Proses ini dilakukan untuk mengurangi dimensi data, meningkatkan efisiensi pelatihan, serta membantu model menghasilkan performa yang lebih baik. Karena dataset memiliki ketidakseimbangan kelas, maka dilakukan percobaan teknik SMOTE yang hanya diterapkan pada data <i>training</i> untuk menghasilkan sampel sintesis pada kelas minoritas. Pada tahap pemodelan, digunakan beberapa algoritma klasifikasi yaitu SVM sebagai model non-ensemble, Random Forest sebagai model ensemble bagging, dan XGBoost sebagai model ensemble boosting. Penelitian ini menggunakan beberapa kondisi pengujian untuk membandingkan performa model secara lebih komprehensif, yaitu: 1) Model tanpa <i>feature selection</i> dan tanpa SMOTE 2) Model dengan <i>feature selection</i> tanpa SMOTE 3) Model tanpa <i>feature selection</i> dengan SMOTE 4) Model dengan <i>feature selection</i> dan SMOTE Setiap kondisi pengujian diuji menggunakan ketiga algoritma klasifikasi sehingga dapat diketahui pengaruh penggunaan <i>feature selection</i>, SMOTE, serta perbedaan performa antara model ensemble dan non-ensemble. Tahap akhir evaluasi model menggunakan data <i>testing</i> dan <i>validation</i> serta dianalisis menggunakan beberapa metrik evaluasi untuk mengukur kemampuan model dalam memprediksi tingkat keseriusan efek samping obat.

	Penelitian ini menggunakan beberapa metrik evaluasi sebagai berikut: 1) <i>Accuracy</i> Digunakan untuk mengukur persentase keseluruhan prediksi yang benar terhadap total data. <i>Accuracy</i> memberikan gambaran umum performa model. Namun, metrik ini saja tidak cukup untuk digunakan dalam evaluasi jika distribusi kelas tidak seimbang. 2) <i>Precision</i> Mengukur seberapa banyak prediksi positif yang benar-benar termasuk kelas positif. <i>Precision</i> penting untuk mengurangi kesalahan prediksi positif palsu (false positive) 3) <i>Recall</i> Mengukur kemampuan model dalam mendeteksi seluruh data positif yang sebenarnya. <i>Recall</i> menjadi metrik penting dalam penelitian ini karena kesalahan dalam mendeteksi kasus efek samping serius dapat berdampak besar terhadap keselamatan pasien. 4) <i>F1-Score</i> <i>F1-Score</i> digunakan untuk memberikan evaluasi yang lebih seimbang pada kondisi data tidak seimbang. 5) <i>Confusion Matrix</i> Digunakan untuk melihat jumlah prediksi benar dan salah pada masing-masing kelas, yaitu <i>True Positive</i> (TP), <i>True Negative</i> (TN), <i>False Positive</i> (FP), dan <i>False Negative</i> (FN). <i>Confusion matrix</i> membantu analisis lebih detail terhadap kesalagkan klasifikasi model Dengan menggunakan beberapa metrik evaluasi tersebut, performa masing-masing model dapat dibandingkan secara lebih komprehensif.
--	--