

Proposal Proyek Pembelajaran Mesin

S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024-C
Ketua	Hidayah Atma Negara (24031554169)
Anggota 1	Najwa Ayu Ramdhani (24031554168)
Anggota 2	Alvida Lewiana (24031554198)
URL Github	https://github.com/atmamta/PROJECT-PEMBELAJARAN-MESIN

Informasi Umum Proyek

Judul	Analisis Perbandingan Model Ensemble dan Non-Ensemble dengan Teknik Oversampling ADASYN untuk Prediksi Keparahan Efek Samping Obat pada Sistem Pelaporan Kejadian Buruk FDA 2015 - 2025 (FAERS)
Topik	Kesehatan
Pilihan Rumusan Masalah	Pemanfaatan AI dan Big Data Kesehatan
Revisi?	<i>Ya / Tidak</i>

Deskripsi Rumusan masalah	Efek samping obat yang tidak diinginkan, terutama yang fatal, merupakan ancaman serius terhadap keselamatan pasien dan membebani sistem kesehatan secara global. Keterlambatan deteksi efek samping ini dapat berakibat fatal dan menimbulkan biaya kesehatan yang masif. Oleh karena itu, pengembangan sistem deteksi dini berbasis kecerdasan buatan menjadi krusial untuk menjamin keamanan pasien dan membantu otoritas kesehatan serta produsen farmasi dalam memprioritaskan investigasi risiko. Di Indonesia, permasalahan ini diperparah oleh beberapa tantangan spesifik: 1. Di Indonesia, penjualan obat, termasuk obat bebas, seringkali tidak disertai edukasi yang komprehensif kepada pasien. Kasus tragis keracunan obat sirup yang menyebabkan 324 kematian anak pada tahun 2022 menyoroti bahaya pengawasan yang longgar dan kurangnya informasi akurat kepada masyarakat. Kondisi ini diperparah oleh variasi pengalaman dan kompetensi apoteker, yang menyebabkan inkonsistensi dalam penyampaian informasi detail mengenai potensi efek samping obat. Akibatnya, kesadaran masyarakat akan risiko efek samping rendah, dan pelaporan kejadian buruk menjadi tidak optimal, menciptakan celah signifikan dalam sistem farmakovigilans nasional. 2. Perbedaan tingkat pengalaman dan pengetahuan antar apoteker di berbagai fasilitas kesehatan di Indonesia dapat menyebabkan inkonsistensi dalam identifikasi dan pelaporan efek samping obat. <i>Medication error</i>, seperti salah obat, salah dosis, atau salah instruksi, dapat terjadi kapan saja, seringkali bukan karena kurangnya niat, melainkan kurangnya sistem pendukung yang memadai. Bahkan, pernah terjadi kasus di RSUD Ryacudu di mana cleaning service diperintahkan meracik obat pasien, yang berujung pada pemberian obat yang tidak sesuai. Sistem yang diusulkan ini diharapkan dapat menjadi alat bantu yang esensial bagi apoteker untuk membuat keputusan yang lebih tepat dan konsisten, sehingga meminimalkan risiko kesalahan pengobatan dan meningkatkan kualitas pelayanan farmasi.
---------------------------	---

	3. Kurangnya deteksi dini dan penanganan efek samping obat yang efektif dapat memperburuk kondisi pasien, yang pada akhirnya memerlukan penanganan medis lebih lanjut dan rujukan ke fasilitas kesehatan yang lebih tinggi. Data BPJS Kesehatan menunjukkan adanya 714 ribu kasus rujukan non-spesialistik per tahun yang membebani anggaran hingga 49,1 miliar rupiah.
Tujuan penelitian (Objectives)	Penelitian ini bertujuan untuk mengembangkan sistem prediksi status keparahan dari efek samping obat dengan tahapan dan target penyelesaian sebagai berikut: 1. Mengumpulkan dan membersihkan data laporan efek samping obat dari FAERS (tahun 2015–2025). Ini termasuk mengisi data yang kosong. 2. Menggunakan ADASYN untuk menyeimbangkan data dan membandingkan data tanpa menggunakan ADASYN. 3. Membuat dan melatih beberapa jenis sistem prediksi dengan membandingkan Ensemble dan Non-Ensemble. 4. Menyajikan temuan penting dari penelitian ini, termasuk faktor-faktor apa saja yang paling berpengaruh terhadap terjadinya efek samping obat yang serius.
Referensi penelitian	Berikut jurnal dan referensi yang kami gunakan: 1. https://doi.org/10.1097/MD.00000000000029387 2. https://doi.org/10.1145/3472813.3472817 3. https://doi.org/10.3389/fphar.2024.1497397 4. https://doi.org/10.37936/ecti-cit.2026201.263596

Informasi Detil Dataset

Sumber dataset	Dataset yang digunakan dalam penelitian ini diperoleh dari platform Kaggle, yang dapat diakses melalui tautan berikut: <u>FDA Drug Adverse Event Reports 2015 to 2025 FAERS</u>. Dataset ini bersumber dari FDA Adverse Event Reporting System (FAERS), yaitu basis data utama milik Amerika Serikat yang memuat informasi laporan keamanan obat, seperti efek samping dan kejadian yang tidak diinginkan yang dikirimkan oleh para profesional kesehatan, produsen, dan pasien dari 162 negara. FAERS dikelola oleh FDA (<i>Food and Drug Administration</i>), yaitu lembaga pemerintahan Amerika Serikat yang bertanggung jawab atas pengawasan keamanan makanan, obat-obatan, produk biologis, alat kesehatan, kosmetik, dan produk kesehatan lainnya. Basis data ini dirancang untuk mendukung pengawasan keamanan dan evaluasi manfaat obat setelah dipasarkan sepanjang siklus hidup produk obat. Proses akuisisi data dilakukan dengan mengunduh dataset yang telah dikompilasi oleh pengguna Kaggle dengan nama akun kanchana1990, yang mencakup 11 tahun data dari periode tahun 2015 hingga 2025. Dataset tersedia dalam format CSV dan dapat langsung digunakan untuk analisis tanpa akuisisi tambahan.					
Deskripsi awal fitur dataset	Dataset ini memiliki 30 atribut dan 528.000 laporan. Tidak semua atribut akan digunakan dalam pemodelan akan dilakukan seleksi fitur untuk memilih subset yang paling relevan dan informatif. Kolom ‘serious_flags’ juga dikategorikan ulang menjadi 5 kelas keparahan (Death, Hospitalization, Disability, Life-Threatening, Congenital Anomaly) yang dijadikan variabel target klasifikasi multi-kelas pada penelitian ini. Daftar atribut yang digunakan pada penelitian ditampilkan pada Gambar 1. Tabel 1. Atribut Dataset Penelitian <table><tr><th>Atribut</th><th>Tipe</th><th>Keterangan</th></tr></table>			Atribut	Tipe	Keterangan
Atribut	Tipe	Keterangan				


	reactions	string	Semua reaksi MedDRA yang dilaporkan (dipisahkan oleh titik koma, hingga 5)
	primary_reaction	string	Reaksi pertama/primer yang dilaporkan
	reaction_outcomes	string	Hasil pasien per reaksi
	patient_recovered	bool	Benar jika pasien sembuh atau sedang dalam masa pemulihan
	num_reaction	int	Jumlah total reaksi yang dilaporkan
	suspect_drug	string	Nama generik obat yang dicurigai
	drug_route	string	Rute pemberian (Oral, Intravena, dll.)
	drug_indication	string	Kondisi medis yang menjadi alasan obat tersebut diresepkan
	pharm_class	string	Kelas obat farmakologis
	num_drugs	int	Jumlah obat yang dikonsumsi pasien
	drug_count_category	string	Kategori Polifarmasi (Sata obat/ 2-3 obat/ 4-5 obat/ 6 obat atau lebih)
	patient_age_years	float	Usia pasien standarisasi menjadi tahun
	patient_sex	string	Jenis kelamin pasien (Laki-laki/ Perempuan/ Tidak diketahui)
	patient_weight_kg	float	Berat pasien dalam kategorikal
Aspek khusus dari dataset	Terdapat beberapa aspek khusus yang perlu diperhatikan dalam dataset ini, meliputi kelengkapan data, ketidakseimbangan kelas, sebaran outlier serta karakteristik umum dataset. 1. Kelengkapan Data (<i>Sparsity</i>) Dataset ini memiliki beberapa kolom yang tidak terisi secara signifikan. Berdasarkan hasil pemeriksaan missing value pada dataset dengan total 528.000 baris dan 30 kolom, kolom <i>patient_weight_kg</i> menjadi kolom dengan kehilangan data terbanyak, yaitu sebesar 379.923 nilai kosong atau sekitar 71,9% dari total baris. Kolom <i>serious_flags</i> memiliki 301.106 nilai kosong (57,0%), namun kondisi ini bersifat struktural karena kolom tersebut memang hanya terisi untuk laporan yang dikategorikan serius sehingga nilai kosong pada kolom ini bukan merupakan missing value yang bersifat acak. Kolom <i>patient_age_years</i> juga memiliki 151.509 nilai kosong (28,7%), sedangkan kolom lainnya tidak memiliki nilai kosong sama sekali. Penanganan missing value dilakukan dengan mengisi kolom bertipe numerik menggunakan nilai median dan kolom bertipe kategorikal menggunakan nilai modus. Setelah penanganan. 2. Ketidakseimbangan Data (<i>Class Imbalance</i>) Distribusi variabel target <i>serious_flags</i> menunjukkan adanya ketidakseimbangan jumlah data pada masing-masing label. Setelah dilakukan transformasi <i>multi-hot encoding</i>, diperoleh lima label utama, yaitu <i>Death</i>,		

	<i>Hospitalization</i>, <i>Disability</i>, <i>Life-Threatening</i>, dan <i>Congenital Anomaly</i>. Berdasarkan hasil distribusi data, label <i>Hospitalization</i> memiliki jumlah kasus tertinggi sebanyak 188.042 data, diikuti <i>Death</i> sebanyak 54.301 data, <i>Life-Threatening</i> sebanyak 22.871 data, <i>Disability</i> sebanyak 13.524 data, dan <i>Congenital Anomaly</i> sebagai label dengan jumlah paling sedikit, yaitu 3.568 data. Perbedaan distribusi antarlabel tersebut menunjukkan adanya ketidakseimbangan kelas (<i>class imbalance</i>) pada dataset multi-label yang digunakan. Ketidakseimbangan data berpotensi menyebabkan model lebih dominan mempelajari label mayoritas dan kurang optimal dalam mengenali label minoritas, terutama pada label dengan jumlah data yang sangat sedikit seperti <i>Congenital Anomaly</i>. Kondisi ini dapat menurunkan kemampuan generalisasi model dalam mendeteksi seluruh kategori tingkat keparahan efek samping obat secara seimbang. 3. Sebaran Outlier Berdasarkan visualisasi boxplot pada seluruh kolom numerik setelah proses <i>preprocessing</i>, ditemukan adanya nilai ekstrem pada beberapa kolom. Kolom <i>num_reactions</i> secara umum terpusat pada rentang rendah, namun terdapat outlier hingga sekitar 250 reaksi per laporan. Kolom <i>num_drugs</i> menunjukkan pola serupa di mana mayoritas pasien mengonsumsi obat dalam jumlah kecil, namun outlier mencapai sekitar 2.000 obat yang kemungkinan merupakan kasus polifarmasi ekstrem atau kesalahan entri data. Pada kolom <i>patient_age_years</i>, distribusi terpusat pada rentang dewasa hingga lansia dengan nilai median sekitar 59 tahun, namun terdapat outlier berupa usia sangat muda (kurang dari 1 tahun) dan sangat tua (lebih dari 100 tahun). Kolom <i>patient_weight_kg</i> memiliki distribusi terpusat dengan median sekitar 72,56 kg, namun ditemukan outlier ekstrem di atas 300 kg. Keberadaan outlier pada kolom-kolom tersebut perlu diperhatikan secara khusus mengingat algoritma SVM bersifat sensitif terhadap perbedaan skala fitur, sehingga normalisasi menggunakan <i>StandardScaler</i> diterapkan sebagai langkah mitigasi.
--	--

Rencana Metode

Teknik yang digunakan	Berikut rencana awal teknik yang kami gunakan: 1. Untuk mengatasi masalah <i>imbalanced data</i>, kami menggunakan teknik oversampling ADASYN (Adaptive Synthetic Sampling). ADASYN bekerja dengan menghasilkan data sintetis secara adaptif pada kelas minoritas, terutama pada data yang sulit dipelajari oleh model. Dengan demikian, distribusi data menjadi lebih seimbang sehingga model dapat melakukan prediksi dengan lebih baik dan mengurangi bias terhadap kelas mayoritas. 2. Model non-ensemble yang kami gunakan sebagai <i>baseline</i> perbandingan adalah Support Vector Machine (SVM). SVM dipilih karena merupakan algoritma klasifikasi yang efektif dalam menangani data berdimensi tinggi dan mampu menghasilkan performa yang baik pada proses klasifikasi. 3. Model ensemble berbasis bagging yang digunakan adalah Random Forest. Random Forest dipilih karena mampu meningkatkan stabilitas dan akurasi prediksi melalui kombinasi banyak <i>decision tree</i>, sehingga dapat mengurangi risiko <i>overfitting</i> pada data pelaporan efek samping obat. 4. Model ensemble berbasis boosting yang digunakan adalah XGBoost. XGBoost dipilih karena memiliki performa yang tinggi dalam klasifikasi data berskala besar dan mampu menangani kompleksitas pola data dengan efisien. Dalam penelitian ini, model XGBoost akan digunakan untuk memprediksi tingkat keparahan efek samping obat pada dataset FAERS 2015–2025.
-----------------------	---

	5. Evaluasi performa model dilakukan menggunakan beberapa metrik klasifikasi seperti <i>Accuracy</i>, <i>Precision</i>, <i>Recall</i>, <i>F1-Score</i>, <i>Hamming Loss</i>, dan <i>Confusion Matrix</i> untuk membandingkan performa model <i>ensemble</i> dan <i>non-ensemble</i> setelah penerapan teknik oversampling ADASYN.
Alasan pemilihan teknik/algoritma	Pemilihan teknik dan algoritma dalam penelitian ini didasarkan pada karakteristik dataset FEARS serta relevansinya terhadap permasalahan prediksi keparahan efek samping obat yang bersifat kompleks dan tidak seimbang. ADASYN (<i>Adaptive Synthetic Sampling</i>) ADASYN (<i>Adaptive Synthetic Sampling</i>) dipilih sebagai teknik penanganan ketidakseimbangan kelas karena kemampuannya yang lebih adaptif dibanding metode oversampling konvensional. Berbeda dengan metode yang menghasilkan sampel sintetis secara seragam, ADASYN memberikan bobot lebih besar pada sampel minoritas yang lebih sulit diklasifikasikan, sehingga distribusi kelas yang dihasilkan lebih representatif. Hal ini relevan mengingat dataset FAERS memiliki <i>imbalance ratio</i> sekitar 2,97:1 yang berpotensi membuat model bias terhadap kelas mayoritas. Pendekatan ini didukung oleh Hu et al. (2024) yang melaporkan bahwa penerapan teknik oversampling terbukti meningkatkan nilai AUC dari rentang 0,601–0,936 menjadi 0,786–0,939, serta Zhou et al. (2021) yang menunjukkan peningkatan F-Measure substansial pada seluruh model setelah penanganan imbalance diterapkan. SVM (<i>Support Vector Machine</i>) <i>Support Vector Machine</i> (SVM) dipilih sebagai model baseline non-ensemble karena kemampuannya menangani data berdimensi tinggi melalui pencarian <i>hyperplane</i> optimal dengan margin terbesar, serta penggunaan fungsi karel untuk menangani data yang tidak dapat dipisahkan secara linier. Kim et al (2022) dan Hu et al (2024) menempatkan SVM sebagai salah satu metode <i>supervised</i> yang paling sering digunakan dalam studi deteksi reaksi obat merugikan. Mengingat SVM sensitif terhadap perbedaan skala fitur, normalisasi menggunakan StandardScaler telah diterapkan sebagai langkah mitigasi dalam tahap <i>preprocessing</i> penelitian ini. Random Forest Random Forest dipilih sebagai representasi model ensemble berbasis bagging karena kemampuannya menggabungkan prediksi dari banyak pohon keputusan yang dibangun secara independen, sehingga secara inheren mengurangi varians dan risiko <i>overfitting</i>. Kemampuan ini relevan mengingat dataset FEARS mengandung fitur heterogen yang mencakup data numerik, kategorikal dan boolean secara bersamaan. Hu et al (2024) menegaskan bahwa Random Forest merupakan algoritma yang paling sering digunakan dalam studi prediksi efek samping obat dengan rata-rata AUC $0,770 \pm 0,104$ sementara Irmawati Aziz (2025) melaporkan Random Forest mencapai AUC 0,891 dengan keunggulan dalam menangani data tidak seimbang pada konteks farmakovigilans. XGBoost XGBoost (<i>Extreme Gradient Boosting</i>) dipilih sebagai representasi model ensemble berbasis boosting karena membina pohon keputusan secara sekuensial, dimana setiap pohon baru difokuskan memperbaiki kesalahan prediksi sebelumnya melalui optimasi loss function dan regularisasi. Hu et al (2024) melaporkan XGBoost sebagai algoritma boosting paling sering diidentifikasi sebagai model optimal dengan rata-rata AUC

	0,810 ± 0,109, melalui performa Random Forest. Zhao et al (2021) juga menunjukkan peningkatan F-Measure sebesar 24,28% pada XGBoost setelah penerapan teknik penanganan imbalance, sekaligus kemampuannya menangani sparsity data secara alami yang relevan dengan kondisi missing value pada dataset FAERS.
Langkah-langkah umum pengerjaan	Dalam penelitian ini, proses pelatihan model dilakukan melalui beberapa tahapan yang dirancang secara sistematis agar model yang dihasilkan mampu memprediksi tingkat keparahan efek samping obat dengan lebih akurat. Berikut disajikan langkah-langkah penelitian pada Gambar 1.  <pre> graph TD Start([Start]) --> Input[/Input/] Input --> EDA[EDA] EDA --> Preprocessing[Preprocessing] Preprocessing --> SplitData[Split Data] SplitData --> ADASYN{ADASYN?} ADASYN --> Model[Model] ADASYN --> ApplyADASYN[Apply ADASYN] Model --> Evaluasi[Evaluasi] ApplyADASYN --> Evaluasi Evaluasi --> Output[/Output/] Output --> End([End]) </pre> Gambar 1. Langkah-langkah Penelitian Berdasarkan Gambar 1, tahap proses pelatihan model dimulai dengan proses input dataset FAERS 2015-2025. Setelah data dimuat, dilakukan <i>Exploratory Data Analysis</i> (EDA) untuk memahami karakteristik data seperti distribusi kelas, statistik deskriptif, outlier, serta hubungan antarfitur. Tahap selanjutnya adalah <i>preprocessing</i>, yang meliputi penanganan missing value, encoding variabel kategorikal, normalisasi data numerik, serta penghapusan atribut yang tidak relevan. Pada penelitian ini, variabel target berupa ‘serious_flags’ yang memiliki karakteristik <i>multi-label classification</i>, yaitu observasi dapat memiliki lebih dari satu kategori keparahan secara bersamaan. Oleh karena itu, target diubah menggunakan teknik <i>multi-hot encoding</i>. Setiap kategori keparahan direpresentasikan menjadi variabel biner terpisah. Setelah preprocessing selesai, dataset dibagi menjadi data <i>training</i>, <i>testing</i>, dan <i>validation</i> dengan rasio 70:15:15. Karena dataset memiliki ketidakseimbangan kelas, maka dilakukan percobaan teknik ADASYN yang hanya diterapkan pada data <i>training</i> untuk menghasilkan sampel sintetis pada kelas minoritas. Pada <i>multi-label classification</i>, proses oversampling dilakukan pada masing-masing variabel target hasil transformasi <i>multi-hot encoding</i> sehingga distribusi label minoritas menjadi lebih seimbang. Pada tahap pemodelan, digunakan beberapa algoritma klasifikasi, yaitu SVM sebagai model non-ensemble, Random Forest sebagai model ensemble bagging, dan XGBoost sebagai model ensemble boosting. Penelitian ini menggunakan beberapa kondisi pengujian untuk membandingkan performa model secara lebih komprehensif, yaitu model dengan penerapan ADASYN dan model tanpa penerapan ADASYN untuk mengukur seberapa besar pengaruh teknik penanganan imbalanced data terhadap model. Setiap kondisi pengujian diuji menggunakan ketiga algoritma sehingga dapat diketahui pengaruh penggunaan ADASYN serta perbedaan performa antara model ensemble dan non-ensemble. Tahap akhir evaluasi model menggunakan data <i>testing</i> dan <i>validation</i> serta dianalisis menggunakan beberapa metrik evaluasi untuk mengukur kemampuan model dalam memprediksi tingkat keparahan efek samping obat. Penelitian ini menggunakan beberapa metrik evaluasi sebagai berikut:

	1) <i>Accuracy</i> Digunakan untuk mengukur persentase keseluruhan prediksi yang benar terhadap total data. Accuracy memberikan gambaran umum performa model. Namun, metrik ini saja tidak cukup untuk digunakan dalam evaluasi jika distribusi kelas tidak seimbang. 2) <i>Precision</i> Mengukur seberapa banyak prediksi positif yang benar-benar termasuk kelas positif. Precision penting untuk mengurangi kesalahan prediksi positif palsu (false positive) 3) <i>Recall</i> Mengukur kemampuan model dalam mendeteksi seluruh data positif yang sebenarnya. Recall menjadi metrik penting dalam penelitian ini karena kesalahan dalam mendeteksi kasus efek samping serius dapat berdampak besar terhadap keselamatan pasien. 4) <i>F1-Score</i> <i>F1-Score</i> digunakan untuk memberikan evaluasi yang lebih seimbang pada kondisi data tidak seimbang. 5) <i>Hamming Loss</i> Digunakan untuk mengukur proporsi kesalahan prediksi label terhadap keseluruhan label yang ada. Semakin kecil nilainya maka semakin baik performa dalam memprediksi kombinasi model 6) <i>Confusion Matrix</i> Digunakan untuk melihat jumlah prediksi benar dan salah pada masing-masing kelas, yaitu <i>True Positive</i> (TP), <i>True Negative</i> (TN), <i>False Positive</i> (FP), dan <i>False Negative</i> (FN). <i>Confusion matrix</i> membantu analisis lebih detail terhadap kesalagan klasifikasi model Dengan menggunakan beberapa metrik evaluasi tersebut, performa masing-masing model dapat dibandingkan secara lebih komprehensif.
--	---